

Muestreo aplicado en R

Base de datos de tuberculosis / Muestreo aleatorio simple y estratificado

Curso: Software para Análisis e Interpretación de la Información para la Investigación Científica (EIC401)

Docente: M.A. Lic. Jaime Andre Chocó Cedillos

Archivo analizado: database_tb_limpia.xlsx

Población: N = 3,104 pacientes

Semilla: set.seed(2026)

Tamaño de cada muestra: n = 300

Fecha: 27 de agosto de 2026

Criterio de cálculo. Las respuestas se calcularon únicamente con la muestra correspondiente. Las medias y medianas excluyen NA cuando el enunciado lo indica; los porcentajes de presencia usan como denominador el total de la muestra o del estrato, según corresponda.

Reproducibilidad: R 4.4.2, readxl 1.4.5 y dplyr 1.1.4.

Ejercicio 1 - Muestreo aleatorio simple

Código de muestreo solicitado

```
# Procedimiento en R
library(readxl)
library(dplyr)
datos <- read_excel("database_tb_limpia.xlsx", sheet = "datos", guess_max = 5000)
datos <- as.data.frame(datos)
set.seed(2026)
n1 <- 300
indices1 <- sample(1:nrow(datos), n1)
muestra1 <- datos[indices1, ]
```

1. Tamaño de la muestra y porcentaje de la base

```
# Procedimiento en R
nrow(muestra1)
100 * nrow(muestra1) / nrow(datos)
```

Resultado: La muestra contiene 300 observaciones, equivalentes al 9.66% de los 3,104 registros de la base.

2. Distribución por sexo

```
# Procedimiento en R
table(muestra1$sexo)
100 * sum(muestra1$sexo == "Masculino") / nrow(muestra1)
```

Resultado: Se seleccionaron 190 hombres y 110 mujeres. Los hombres representan el 63.33% de la muestra.

3. Edad al diagnóstico: media, mediana y valores faltantes

```
# Procedimiento en R
mean(muestra1$edad_al_diagnostico, na.rm = TRUE)
median(muestra1$edad_al_diagnostico, na.rm = TRUE)
sum(is.na(muestra1$edad_al_diagnostico))
```

Resultado: La edad media al diagnóstico es 36.35 años y la mediana es 34.00 años. La variable presenta 20 valores faltantes.

4. Porcentaje de pacientes fallecidos

```
# Procedimiento en R
100 * sum(muestra1$pronostico == "Fallecido") / nrow(muestra1)
```

Resultado: Fallecieron 65 pacientes, lo que corresponde al 21.67% de la muestra.

5. Categoría más frecuente de edad_rangos y datos faltantes

```
# Procedimiento en R
tabla_edad <- table(muestra1$edad_rangos)
names(which.max(tabla_edad))
max(tabla_edad)
sum(is.na(muestra1$edad_rangos))
```

Resultado: La categoría más frecuente es "18 a 35 años", con 121 pacientes. Hay 20 valores NA en edad_rangos (280 datos disponibles).

6. Porcentaje con coinfección

```
# Procedimiento en R
100 * sum(muestra1$coinfeccion == "Sí") / nrow(muestra1)
```

Resultado: Presentan coinfección 158 pacientes, equivalentes al 52.67% de la muestra.

7. Diagnóstico de VIH positivo

```
# Procedimiento en R
n_vih <- sum(muestra1$dx_vih == "Sí")
c(n = n_vih, porcentaje = 100 * n_vih / nrow(muestra1))
```

Resultado: Tienen diagnóstico de VIH positivo 158 pacientes, equivalentes al 52.67%.

8. Clasificación según tipo_de_tb

```
# Procedimiento en R
tabla_tipo <- table(muestra1$tipo_de_tb)
tabla_tipo
names(which.max(tabla_tipo))
```

Resultado: Extrapulmonar: 141 casos; Pulmonar: 127; Profilaxis: 32. La categoría más frecuente es Extrapulmonar, con 141 casos.

9. Valores disponibles y media de cd4

```
# Procedimiento en R
sum(!is.na(muestra1$cd4))
mean(muestra1$cd4, na.rm = TRUE)
```

Resultado: Hay 84 valores disponibles de cd4. Su media es 140.99 células/ml.

10. Año con mayor número de pacientes

```
# Procedimiento en R
tabla_anio <- table(muestra1$anio)
tabla_anio
names(which.max(tabla_anio))
```

Resultado: El año con mayor representación es 2014, con 45 pacientes.

11. Pacientes con seguimiento Activo

```
# Procedimiento en R
sum(!is.na(muestra1$seguimiento))
sum(muestra1$seguimiento == "Activo", na.rm = TRUE)
```

Resultado: Los 300 pacientes tienen seguimiento registrado y 164 se encuentran en estado Activo.

12. Baciloscopia positiva y valores faltantes

```
# Procedimiento en R
n_pos <- sum(muestra1$baciloscopia == "Sí", na.rm = TRUE)
100 * n_pos / nrow(muestra1)
sum(is.na(muestra1$baciloscopia))
```

Resultado: La baciloscopia es positiva en 230 pacientes, equivalentes al 76.67% de la muestra. Hay 21 valores NA.

13. Contacto con un caso de tuberculosis

```
# Procedimiento en R
n_contacto <- sum(muestra1$concontacto == "Sí", na.rm = TRUE)
100 * n_contacto / nrow(muestra1)
```

Resultado: Nueve pacientes reportan contacto con un caso de tuberculosis, equivalentes al 3.00% de la muestra. La variable se llama concontacto en la base.

14. Media y valores faltantes de meses_diagnostico_vih

```
# Procedimiento en R
mean(muestra1$meses_diagnostico_vih, na.rm = TRUE)
sum(is.na(muestra1$meses_diagnostico_vih))
```

Resultado: La media es 56.66 meses, calculada con los valores disponibles. La variable contiene 18 valores NA.

15. Tabla de frecuencias de cultivo e interpretación

```
# Procedimiento en R
tabla_cultivo <- table(muestra1$cultivo, useNA = "ifany")
prop.table(tabla_cultivo)
100 * prop.table(tabla_cultivo)
```

Resultado: El resultado Positivo es el más frecuente (155; 51.67%), seguido de 84 valores faltantes (28.00%) y 61 resultados Negativos (20.33%). En consecuencia, poco más de la mitad de la muestra tiene cultivo positivo; sin embargo, el 28.00% sin dato debe considerarse al interpretar la distribución.

Categoría	Frecuencia	Proporción	Porcentaje
Negativo	61	0.2033	20.33%
Positivo	155	0.5167	51.67%
NA	84	0.2800	28.00%
Total	300	1.0000	100.00%

Fuente: cálculo propio con muestra1 (n = 300), set.seed(2026).

Ejercicio 2 - Muestreo estratificado por sexo

Código de muestreo solicitado

```
# Procedimiento en R
datos <- read_excel("database_tb_limpia.xlsx", sheet = "datos", guess_max = 5000)
datos <- as.data.frame(datos)

set.seed(2026)
n_total <- 300
prop_masc <- sum(datos$sexo == "Masculino") / nrow(datos)
n_masc <- round(n_total * prop_masc)
n_fem <- n_total - n_masc

datos_masc <- datos[datos$sexo == "Masculino", ]
datos_fem <- datos[datos$sexo == "Femenino", ]

muestra_masc <- datos_masc[sample(1:nrow(datos_masc), n_masc), ]
muestra_fem <- datos_fem[sample(1:nrow(datos_fem), n_fem), ]
muestra2 <- rbind(muestra_masc, muestra_fem)
```

1. Composición de la muestra estratificada y verificación proporcional

```
# Procedimiento en R
table(muestra2$sexo)
100 * prop.table(table(muestra2$sexo))
100 * prop.table(table(datos$sexo))
```

Resultado: La muestra contiene 189 hombres (63.00%) y 111 mujeres (37.00%). En la base completa hay 1,960 hombres (63.14%) y 1,144 mujeres (36.86%); por tanto, la asignación es consistente con la proporción poblacional, con la diferencia esperable por redondeo.

2. Porcentaje de fallecidos por sexo

```
# Procedimiento en R
tab <- table(muestra2$sexo, muestra2$pronostico)
100 * prop.table(tab, margin = 1)[, "Fallecido"]
```

Resultado: Falleció el 18.92% de las mujeres (21 de 111) y el 30.16% de los hombres (57 de 189).

3. Sexo con mayor porcentaje de fallecidos

```
# Procedimiento en R
pct_fallecidos <- 100 * prop.table(tab, margin = 1)[, "Fallecido"]
names(which.max(pct_fallecidos))
```

Resultado: El porcentaje de fallecidos es mayor en los hombres: 30.16%, frente a 18.92% en las mujeres; la diferencia descriptiva es de 11.24 puntos porcentuales.

4. Edad promedio al diagnóstico por sexo

```
# Procedimiento en R
aggregate(edad_al_diagnostico ~ sexo, muestra2,
          FUN = function(x) mean(x, na.rm = TRUE))
```

Resultado: La edad promedio al diagnóstico es 35.80 años en hombres y 33.07 años en mujeres. Se excluyeron los valores NA del cálculo.

5. Mediana de la edad al diagnóstico por sexo

```
# Procedimiento en R
aggregate(edad_al_diagnostico ~ sexo, muestra2,
          FUN = function(x) median(x, na.rm = TRUE))
```

Resultado: La mediana es 33 años en hombres y 32 años en mujeres. Por lo tanto, la mediana es mayor en los hombres.

6. Diagnóstico de VIH positivo por sexo

```
# Procedimiento en R
tab_vih <- table(muestra2$sexo, muestra2$dx_vih)
100 * prop.table(tab_vih, margin = 1)[, "Sí"]
```

Resultado: El 54.50% de los hombres tiene diagnóstico de VIH positivo (103 de 189), frente al 45.95% de las mujeres (51 de 111).

7. Tipo de tuberculosis más frecuente por sexo

```
# Procedimiento en R
tab_tipo <- table(muestra2$sexo, muestra2$tipo_de_tb)
apply(tab_tipo, 1, function(x) c(categoria = names(which.max(x)), n = max(x)))
```

Resultado: En ambos sexos predomina la tuberculosis Extrapulmonar: 86 casos en hombres y 58 casos en mujeres. En hombres siguen Pulmonar (81) y Profilaxis (22); en mujeres, Pulmonar (38) y Profilaxis (15).

8. Porcentaje con coinfección por sexo

```
# Procedimiento en R
tab_coinf <- table(muestra2$sexo, muestra2$coinfeccion)
100 * prop.table(tab_coinf, margin = 1)[, "Sí"]
```

Resultado: Presenta coinfección el 45.95% de las mujeres (51 de 111) y el 54.50% de los hombres (103 de 189).

9. Comparación del seguimiento Fallecido

```
# Procedimiento en R
tab_seg <- table(muestra2$sexo, muestra2$seguimiento)
tab_seg[, "Fallecido"]
```

Resultado: Hay 57 hombres y 21 mujeres con seguimiento Fallecido. El mayor número corresponde a los hombres.

10. Valores NA de edad_rangos por sexo

```
# Procedimiento en R
tapply(is.na(muestra2$edad_rangos), muestra2$sexo, sum)
```

Resultado: No tienen dato en edad_rangos 12 mujeres y 6 hombres.

11. Baciloscopia positiva por sexo

```
# Procedimiento en R
n_pos <- tapply(muestra2$baciloscopia == "Sí", muestra2$sexo,
               function(x) sum(x, na.rm = TRUE))
100 * n_pos / table(muestra2$sexo)
```

Resultado: La baciloscopia es positiva en el 71.43% de los hombres (135 de 189; 16 NA) y en el 70.27% de las mujeres (78 de 111; 14 NA). Los porcentajes usan el total de cada estrato como denominador.

12. Media de cd4 por sexo

```
# Procedimiento en R
muestra2 %>% group_by(sexo) %>%
  summarize(n = sum(!is.na(cd4)), media = mean(cd4, na.rm = TRUE))
```

Resultado: La media de cd4 es 138.95 células/ml en mujeres (20 datos disponibles) y 121.53 células/ml en hombres (58 disponibles). La media es mayor en las mujeres.

13. Rango de edad con mayor concentración por sexo

```
# Procedimiento en R
tab_rango <- table(muestra2$sexo, muestra2$edad_rangos)
apply(tab_rango, 1, function(x) c(rango = names(which.max(x)), n = max(x)))
```

Resultado: En ambos sexos el rango más frecuente es 18 a 35 años: 39 mujeres y 84 hombres.

14. Casos de seguimiento Abandono por sexo

```
# Procedimiento en R
tab_seg[, "Abandono"]
```

Resultado: Hay 1 caso de Abandono entre las mujeres y 6 entre los hombres.

15. Síntesis de diferencias entre hombres y mujeres

```
# Procedimiento en R
sprintf("Fallecidos: H %.2f%%, M %.2f%%; abandono: H %d, M %d; CD4: H %.2f, M %.2f",
       30.16, 18.92, 6, 1, 121.53, 138.95)
```

Resultado: Los hombres presentaron mayor mortalidad que las mujeres (30.16% frente a 18.92%), con 57 y 21 casos de seguimiento Fallecido, respectivamente. También hubo más abandonos entre los hombres (6 frente a 1) y una media de cd4 menor entre sus datos disponibles (121.53 frente a 138.95 células/ml). La positividad de la baciloscopia fue muy similar (71.43% en hombres y 70.27% en mujeres). En conjunto, la muestra muestra una evolución descriptivamente menos favorable en los hombres, sin que estos resultados demuestren causalidad.

Nota final

Todas las cifras proceden de las muestras generadas con `set.seed(2026)`. El archivo `Examen_Muestreo_Resuelto.R` contiene el código completo, comentado y ejecutable que reproduce estos resultados.